

Caroline KOUDORO-PARFAIT

DIGITAL HUMANITIES RESEARCHER

PHD · COMPARATIVE LITERATURE AND NATURAL LANGUAGE PROCESSING

Sorbonne Université, Paris, France

✉ caroline.parfait10@gmail.com | 🏠 carolinekoudoroparfait.github.io | 📄 [These-SCAI2023](#)

Keywords : Historical Data and Archives, Noisy data, AI systems, User-centered design, Interdisciplinary research

Experience

- 2025-2026 **Adjunct Lecturer (fixed-term contract, 4 hours/week) in Digital Arts and Applied Arts (DSAA) – Master's degree**, ENSAAMA, Olivier de Serres, Paris, France
- 2023-2025 **Temporary Teaching and Research Fellow (ATER)**, (two one-year fixed-term contracts), Department of Sociology and Computer Science, Sorbonne University, Paris, France
- 2020-2023 **Contractual PhD candidate. Funded by the Sorbonne Center for Artificial Intelligence**, Sorbonne University, Paris, France
- 2021-2023 **Adjunct Lecturer, Python Programming**, National Institute for Oriental Languages and Civilizations (INALCO), Paris, France
- 2010-2022 **French Literature Tutor, group and individual lessons – High School level**, Acadomia, Versailles, France
- Mar- Aug 2020 **Internship in Digital Humanities Engineering: Design and development of a digital library with Omeka S and review of digital tools for Social Sciences and Humanities**, Acatu Informatique, Orléans, France

Education

PhD in Comparative Literature and Natural Language Processing (NLP)

Paris, France

SORBONNE UNIVERSITY (SU)

Oct 2020–Nov 2024

- PhD thesis title:

Exploring 19th-Century Literary Space using AI: Evaluation and Analysis of Spatial Named Entity Recognition Tools.

- Dissertation defense scheduled for January 6, 2025
- PhD supervisors: Glenn Roe (ObTIC & CELLF), Gaël Lejeune (STIH); Co-supervisor: Motasem Alrahabi (ObTIC)

Master's degree in Data Intelligence for Culture and Heritage

Tours, France

CENTRE FOR ADVANCED RENAISSANCE STUDIES (CESR), UNIVERSITY OF TOURS

2018 – 2020

- Master's thesis title: *Inventorying, Modeling, Designing, Evaluating: Digital Humanities Challenges and Practices within a Software Development Company.*
- Master's thesis advisor: Elena Pierazzo

Master's degree in Fine arts – Diplôme National Supérieur d'Expression Plastique (DNSEP)

Cergy, France

ÉCOLE NATIONALE SUPÉRIEURE D'ARTS DE PARIS-CERGY (ENSAPC)

2011 – 2017

- Master's thesis title: *L'inertie, le mouvant*
- Master's thesis advisor: François Bon
- Artistic practices: screen printing, video, creative writing, and digital writing

Erasmus+ Exchange Program

Oslo, Norway

OSLO NATIONAL ACADEMY OF THE ARTS (KHIO)

2014

- Fine arts / visual arts, textile department

Master's level degree in Philosophy: Aesthetics and Philosophy of Art

Paris, France

PARIS IV - SORBONNE

2007 – 2011

- Minors: Philosophy and History of Science, Logical Languages, Communication, Political and Ethical Philosophy

Publications

INTERNATIONAL PEER-REVIEWED CONFERENCES

Épiméthée : a workflow from OCR to spatial mapping. Koudoro-Parfait C., Hernandez M., Lejeune, G. et Yoann Dupont, accepté à la conférence ICDAR 2025 (CORE A).

Évaluer les erreurs d'étiquetage de la reconnaissance d'entités nommées sur des transcriptions OCR de romans français. Koudoro-Parfait C., Fief C. 2025. Humanistica 2025.

Mapping spatial named entities from noisy OCR output: Épiméthée from OCR to map. Koudoro-Parfait C., Alrahabi, M., Dupont, Y., Lejeune, G., Roe, G. 2023. Scholger, W., Vogeler, G., Tasovac, T., Baillot, A., Helling, P., ADHO Digital Humanities Conference 2023 (DH2023) Graz. <https://doi.org/10.5281/zenodo.8108050> (DOI).

Évaluation de la tâche de clustering pour l'alignement de formes contaminées d'entités nommées issues d'un corpus OCR bruité. Koudoro-Parfait C.. 2022. Corro, C., Lejeune, G. Actes de la journée d'étude sur la robustesse des systèmes de TAL, p. 5.

Reconnaissance d'entités nommées sur des sorties OCR bruitées: des pistes pour la désambiguïsation morphologique automatique. Koudoro-Parfait C., Lejeune G., Buth, R. 2022. Actes de la 29e Conférence sur le Traitement Automatique des Langues Naturelles. Atelier TAL et Humanités Numériques (TAL-HN), p. 45-55.

Spatial Named Entity Recognition in Literary Texts: What is the Influence of OCR Noise ?. Koudoro-Parfait C., Lejeune, G., Roe, G. 2021. Moncla, L., Brando, C., McDonough, K. GeoHumanities@SIGSPATIAL 2021: Proceedings of the 5th ACM, SIGSPATIAL International Workshop on Geospatial Humanities, Beijing, China, 2 - 5 Novembre, p. 13-21.

Reconnaissance d'entités nommées spatiales dans des transcriptions OCR bruitées de textes littéraires. Koudoro-Parfait C., Lejeune, G. 2021. Atelier Humanités Numériques Spatialisées SAGEO 2021.

Discovering Spatial Relations in Literature : What is the influence of OCR noise?. Koudoro-Parfait C., Lejeune, G. 2021. News-Eye International Conference, Programme de l'Union Européenne.

INTERNATIONAL PEER-REVIEWED JOURNALS

Analyse multilingue de l'impact de la correction automatique de l'OCR sur la reconnaissance d'entités nommées spatiales dans des corpus littéraires. Koudoro-Parfait C., Petkovic, L., ROE, G. 2025. Revue TAL n°66, pp. 5-30.

NATIONAL PEER-REVIEWED CONFERENCES

Correction automatique des interférences OCR dans la reconnaissance d'entités nommées spatiales : réel gain ou perte de l'information ?. Koudoro-Parfait C., Petkovic, L., Lejeune, G. 2023. Journée d'étude à Grenoble coorganisée par l'Université Grenoble Alpes et Roma La Sapienza.

De la création des corpus numériques à leur utilisation : les interférences dans la reconnaissance d'entités nommées spatiales. Koudoro-Parfait C., Lejeune, G. 2022. Séminaire "Des sources aux systèmes d'information géographique : des outils pour la cartographie dans les humanités numériques", Laboratoire DYPAC UVSQ Paris-Saclay, Plateforme Géomatique de EHESS.

NATIONAL PEER-REVIEWED JOURNALS

Quelle solution pour améliorer les performances de la reconnaissance d'entités nommées sur des données bruitées, corriger l'entrée ou filtrer la sortie ?. Petkovic, L., Koudoro-Parfait C., Lejeune, G. 2025. Revue Corpus n°26. Bruit de fond ou valeur ajoutée ? Gérer le bruit lors des traitements informatiques des corpus linguistiques.

PEER-REVIEWED BOOK CHAPTERS

Reconnaissance des Entités Nommées spatiales sur un corpus littéraire bruité : des entités à la carte. Koudoro-Parfait C., Lejeune G. Chapitre dans l'ouvrage "Des sources aux systèmes d'information géographique : des outils pour la cartographie dans les humanités numériques", Laboratoire DYPAC UVSQ Paris-Saclay, Plateforme Géomatique de EHESS. Editions Matériologiques dans la collection Modélisations, simulations, systèmes complexes. Chapitre accepté, à paraître.

INTERNATIONAL WORKSHOPS WITH PEER REVIEW

SPQR@Deft2023: Résolution automatique de QCM médicaux à partir de corpus de domaine et de mesures de similarité. Bezançon J., Boubehziz T., Chutaux C., Zine O., Acensio, L., Koudoro-Parfait C., Briglia A., Lejeune G. 2023. Actes du Défi Fouille de Textes@TALN2023, ATALA, Paris, France. https://coria-taln-2023.sciencesconf.org/data/proceedings_DEFT.pdf hal-04131847

Stylo@ DEFT2022: Notation automatique de copies d'étudiant·e·s par combinaisons de méthodes de similarité. Ben Ltaifa, I., Boubehziz, T., Briglia, A., Chutaux, C., Dupont, Y., González-Gallardo, C., Koudoro-Parfait C., Lejeune, G. 2022. Actes de la 29e Conférence sur le Traitement Automatique des Langues Naturelles. Atelier Défi Fouille de Textes (DEFT), ATALA, p. 11-22.

Annotation et REN sur des OCR bruités : données, utilisateurs, outils. Koudoro-Parfait C.. 2022. Séminaire doctoral, Natural Language Processing meets Digital Humanities, Baillet, A., Magué, J.-P.

Réutiliser les corpus numériques constitués par OCR : bruit et silence dans les data papers. Koudoro-Parfait C., Lejeune, G., Tanguy, J.-B. 2021. DHNord2021.

INVITED CONFERENCES AND SEMINARS

Explorer la collection Française d'ELTeC avec l'outil de cartographie textuelle Epiméthée. Koudoro-Parfait C.. 2025. Dumenieu, B., Abadie, N., Brando, C., Moncla, L. SAGEO2025, Ateliers MAGIS. Humanités numériques spatialisées.

L'impact de l'IA sur les pratiques documentaires : regards croisés entre chercheurs et bibliothécaires. Koudoro-Parfait C., Bouchard, A., Solnon, C. 2024. Bouju, P. ENSSIB.

Table ronde : s'approprier sa recherche. La posture des doctorantes et doctorants ..., axe : « ... face aux Intelligences artificielles (IA) ». Koudoro-Parfait C., Nascimento, L., Courtois, M. 2024. Sorbonne Actuelle 2024. Collectif doctoral.

Garder trace de son travail et le partager en traitement automatique des langues. Koudoro-Parfait C.. 2023. Atelier Digit_Hum 2023, Manipuler des données en SHS : R, Python et les carnets interactifs. Massot M.-L., Tricoche, A., Schultz, E. École normale supérieure.

OCR impact on Named Entity Recognition on historical documents : Problem Presentation ...and Epistemological consequences. Koudoro-Parfait C., Lejeune, G. 2023. Summer School on Digital Humanities, UNAM/SCAI, Université nationale autonome du Mexique.

Reconnaissance d'entités nommées spatiales dans des textes bruités : vers une cartographie littéraire. Koudoro-Parfait C.. 2022. Journée d'étude organisée par ObTIC : Analyse spatiale des textes littéraires, Alrahabi, M, Roe, G.

Des formats de données pour mes sources : un casse-tête ?! Koudoro-Parfait C. 2022. Séminaire doctoral CERES. Grison, T., Bordier, C.

Reconnaissance des Entités Nommées (REN) spatiales dans un corpus littéraire : robustesse des systèmes existants ?. Koudoro-Parfait C. 2021. Séminaire Humanités Numériques Littéraires, Roe, G., ObTIC.

OTHER CONTRIBUTIONS

Espace Numérique du Vitrail - ENVi, Développer une plate-forme numérique sur les données de restauration du vitrail en France. Koudoro-Parfait C., Arruga, M. 2020. Colloque Humanistica 2020.

Premières pages, d/m/c n° 492, 2009 de Claude Rutault. Ouvrage collaboratif en hommage au travail de Claude Rutault, sous la direction de Françoise et Jean-philippe Billarant, collectionneurs, ainsi que Véronique Joumard et Christophe Cuzin artistes plasticiens et enseignants à l'ENSAPC. 2013. Éditions des cendres, p. 181.

Other Research-Related Activities

ORGANIZATION OF THE SEMINAR **NER FOR HISTORICAL DOCUMENTS**

<https://ner-for-historical-docs.github.io/>

NER4Archives : reconnaître, réconcilier et identifier les entités nommées dans les instruments de recherche archivistiques au format EAD. Clavaud, F., Graiff, C. 30 mai 2024. [Koudoro-Parfait C.](#), Chazalon, J., Lejeune, G., Dumenieu, B., Abadie, N., Kermorvant, C. NER for historical documents.

Extraction d'informations structurées dans des documents historiques. Tarride, S. 28 mars 2024. Kermorvant, C., [Koudoro-Parfait C.](#), Chazalon, J., Lejeune, G., Dumenieu, B., Abadie, N. NER for historical documents.

Approches pour la reconnaissance d'écriture et la reconnaissance d'entités nommées. Paquet, T., Coquenat, D., Constum, T. 16 novembre 2023. Chazalon, J., [Koudoro-Parfait C.](#), Lejeune, G., Dumenieu, B., Abadie, N., Kermorvant, C. NER for historical documents.

Analyser les entités dans les romans pour détecter des tendances historiques (grâce au projet BookNLP). Poibeau, T. 19 octobre 2023. Chazalon, J., [Koudoro-Parfait C.](#), Lejeune, G., Dumenieu, B., Abadie, N., Kermorvant, C. NER for historical documents.

Annuaire de propriétaires et des propriétés de Paris (1898, 1903, 1913, 1923) : du papier à la carte. Brando Lebas, C., Mélanie-Becquet, F. 17 mars 2023. [Koudoro-Parfait C.](#), Chazalon, J., Lejeune, G., Dumenieu, B., Abadie, N., Kermorvant, C. NER for historical documents.

Impact de la reconnaissance optique des caractères sur la reconnaissance des entités nommées. Doucet, A., Boros, E. 16 septembre 2022. Lejeune, G., [Koudoro-Parfait C.](#), Chazalon, J., Dumenieu, B., Abadie, N., Kermorvant, C. NER for historical documents.

Session d'introduction. ORGANISATEURS SÉMINAIRE. 7 juillet 2022. Abadie, N., Dumenieu, B., Chazalon, J., [Koudoro-Parfait C.](#), Kermorvant, C., Lejeune, G. NER for historical documents.

WORKSHOP ORGANIZATION

De l'OCR à la visualisation de données. [Koudoro-Parfait C.](#), Hernandez, M. 2024. Atelier ObTIC, BnF.

Utilisation des techniques de transcription automatique des textes pour l'analyse de documents maritimes dactylographiés du XXe siècle. [Koudoro-Parfait C.](#), Petkovic, L. École d'été d'Analyse Numérique de l'Histoire de la Mer et des Océans (AN-HIMO 2023). Institut de l'Océan de l'Alliance Sorbonne Université et Sorbonne Center for Artificial Intelligence (SCAI), Paris (France), 26-30 juin 2023.

Workshop ROC & NER. [Koudoro-Parfait C.](#), Tanguy, J.-B. 2021. Maison de la recherche, Sorbonne Université, Paris.

COMMUNITY INVOLVEMENT

Exploration de la collection Française d'ELTeC avec l'outil de cartographie textuelle Epiméthée. [Koudoro-Parfait C.](#). 2025. Séminaire de l'équipe Variation Linguistique et Linguistique Computationnelle. Couffignal, G., Lejeune, G. Laboratoire Sens Texte Informatique Histoire.

Annoter un corpus bruité quelles difficultés et perspectives. [Koudoro-Parfait C.](#). 2024. Séminaire de l'équipe Variation Linguistique et Linguistique Computationnelle. Couffignal, G., Lejeune, G. Laboratoire Sens Texte Informatique Histoire.

Regrouper des Entités Nommées de Lieux issues d'océrisation : Epiméthée de l'OCR à la carte (Mapping spatial named entities from noisy OCR output: Epimethee from OCR to map). [Koudoro-Parfait C.](#), Lejeune, G. 2023. Séminaire de l'équipe Variation Linguistique et Linguistique Computationnelle. Couffignal, G., Lejeune, G. Laboratoire Sens Texte Informatique Histoire.

Groupe de Travail OCR. [Koudoro-Parfait C.](#) 2023. Variation Linguistique et Linguistique Computationnelle. Couffignal, G., Lejeune, G. Laboratoire Sens Texte Informatique Histoire.

Correction automatique des interférences OCR dans la reconnaissance d'entités nommées spatiales : réel gain ou perte de l'information ?. [Koudoro-Parfait C.](#), Petkovic, L. 2023. Séminaire de l'équipe Variation Linguistique et Linguistique Computationnelle. Couffignal, G., Lejeune, G. Laboratoire Sens Texte Informatique Histoire.

Cybernetics and Society - The Human Use of Human Beings. N. Wiener, 1950. Koudoro-Parfait C. 2023. Club de lecture ML4DH, CERES, SCAI, ObTIC.

Évaluation des résultats de NER sur des transcriptions OCR bruitées par élaboration de supports cartographiques. Koudoro-Parfait C. 2022. Séminaire de l'équipe de Linguistique Computationnelle. Millour, A., Lejeune, G. Laboratoire Sens Texte Informatique Histoire.

Reconnaissance d'entités nommées dans des textes de littérature française du 19ème : le poids du bruit ?. Koudoro-Parfait C. 2021. Séminaire de l'équipe de Linguistique Computationnelle. Millour, A., Lejeune, G. Laboratoire Sens Texte Informatique Histoire.

ASSOCIATIVE ACTIVITIES

Adhérente de l'Association pour le Traitement Automatique des Langues, ATALA. 2022 - Présent.

Participation à la création et adhérente de l'Association des étudiants en IA de Sorbonne Université, SOPhIA. 2021 - Présent.

Teaching Experience

Teaching load (in French system: HETD – Heures Équivalent TD):

ADJUNCT LECTURER, DSAA 2 IN DIGITAL DESIGN (MASTER'S DEGREE) – ENSAAMA, 2025–2026

Course Title	Years	Level	Contact Hours		Materials
			Lectures	Tutorials	
AI Systems for Creative Practice (VR, Video Games): Theory and Applications. Programming in Python, C#, C++	2025-26	M2	108	72	In development

TEMPORARY TEACHING AND RESEARCH FELLOW (ATER), LINGUISTICS AND COMPUTER SCIENCE – SORBONNE UNIVERSITY, 2023–2025

Lead lecturer for lectures and tutorials in Python programming, Undergraduate Year 3 (L3), Sorbonne University, 2024–2025.

Course Title	Years	Level	Contact Hours		Materials
			Lectures	Tutorials	
Python Programming S5, S6	2023-25	L3	126	84	https://github.com/These-SCAI2023/L5SOPRG_2023-2024 ; https://github.com/These-SCAI2023/L6SOPROG/tree/main/PDF_CKP
Digital Humanities	2023-24	M2	3	–	https://github.com/These-SCAI2023/M4LFHUNU
Lexical Analysis in NLP	2023-25	M1	1,5	4,5	Moodle, SU
Computational Linguistics	2023-25	L2	–	6,5	Moodle, SU
PIX – Programming and Problem Solving in Computer Science	2023-25	L2	10,5	144	Moodle, SU
Total			141	239	

ADJUNCT LECTURER, PYTHON PROGRAMMING – INALCO, 2021–2023

Course Title	Years	Level	Contact Hours		Materials
			Lectures	Tutorials	
Algorithms and Data Structuring; Python Programming	2021-23	L3	72	96	https://github.com/These-SCAI2023/Algorithmique_INALCO_2021-2023

SUPERVISION OF MASTER THESES AND INTERNSHIPS

Year	Topic	Type	Student(s)	University
2025	<i>Named Entity Recognition on a Corpus of 19th-Century Poems</i>	Master's thesis (M1), Linguistics	LOPES M., ZHENG R.	SU
2025	<i>Training and Evaluation of a Named Entity Recognition Model on Noisy Data</i>	Master's thesis, Linguistics	FIEF C., CANONGE Y.	SU
2024	<i>Evaluation of Tagging Issues in Named Entity Recognition</i>	Undergraduate internship, Linguistics	FIEF C.	SU
2023	<i>Evaluation and Development of Methods for the Semantic Disambiguation of Spatial Named Entities</i>	Master's internship, IDCP ^a	DORLÉANS C.	CESR
2022	<i>Solving Entity Linking Issues in Noisy OCR Outputs</i>	Master's thesis, Linguistics	BUTH P.-R.	SU
2021	<i>Parisian Places in French Popular Music</i>	Master's thesis, Linguistics	LAZREG M.	SU

^a Data Intelligence for Culture and Heritage.

Tools and Resources Developed

ÉPIMÉTHÉE : FROM OCR TO SPATIAL MAPPING

Epiméthée was developed as part of Caroline Koudoro-Parfait's doctoral research, in collaboration with Yoann Dupont (Lattice, Sorbonne Nouvelle) and Marceau Hernandez (CERES, Sorbonne University).

Epiméthée is a tool designed to:

- Extracts spatial named entities from digitized texts
- Applies clustering and combines multiple NER systems to resolve ambiguities in entity recognition
- Provides an interactive map interface for visualizing spatial entities and filtering out false positives
- Offers a user-friendly interface to enable efficient exploration and interpretation of results

Épiméthée is currently hosted free of charge on a personal server while the ObTIC team updates their server. If the website returns an error, please do not hesitate to contact me.

<https://github.com/These-SCAI2023/EPIMETHEE?tab=readme-ov-file>

METHODOLOGICAL CONTRIBUTIONS IN DIGITAL HUMANITIES

Presentation of methodological directions for evaluating the impact of OCR noise on Named Entity Recognition (NER).

https://github.com/These-SCAI2023/EXPE39_DHENS-2023_13092023

Skills and Interests

PROGRAMMING LANGUAGES AND TOOLS :

- Python, R, HTML5 / CSS3
- Matplotlib, Seaborn, Pandas, OpenCv, Rstudio, Gephy
- Spacy, Stanza, Bert, Flair, CasEn, SEM, Unitex, TXM
- XML-TEI/MEI/EAD, Dublin Core, RDF, RDFs, CIDOC-CRM
- QGIS, Unity, inDesign, Photoshop, illustrator
- $\text{\LaTeX}$

RESEARCH INTERESTS

- Variability in data
- Applicability of AI systems to noisy data
- User-centered design
- Computational analysis of historical and archival data in humanities and social sciences
- Multimodal processing of textual and visual sources (OCR, image analysis, NLP)