

Audition EPITA – Équipe Méthodes Numériques en Sciences Humaines et Sociales .

Caroline Koudoro-Parfait

parfait@uni-trier.de

<https://hal.science/tel-05042915>

5 juin 2026

Universität Trier Fachbereich III - Neuere Geschichte

Parcours universitaire

Humanités Numériques : espace de ma recherche

Le numérique au service d'utilisateur·ice·s non expert·e·s

Doctorat, Littératures françaises et comparées, HN, 2020 - 2024

Combiner pratiques plastiques et numériques

Diplôme national supérieure d'expression Plastique, ENSAPC, 2017

À l'interface : utilisatrice hier, conceptrice demain

Master IDCP (HN), CESR, 2020

Nouer philosophie de l'art et des sciences

Maîtrise de Philosophie, Sorbonne Université, 2011.


- Variabilité dans les données
- Robustesse des systèmes
- Extraction d'informations à grande échelle

Relier les sociétés métropolitaines et coloniales grâce aux archives : les défis numériques de l'extraction d'informations dans la recherche socio-historique

mots clés : Archives, HTR, Données bruitées, REN, Analyse de réseaux

- Université de Trèves, Centre des humanités numériques ;
- Damien Tricoire, Historien moderniste ;
- octobre 2025 - septembre 2027 ;

 site web du projet : <https://carolinekparfait.github.io/>



- **OCR sur des images de qualité variable** avec Toufik Boubehziz (Arts et Métiers) et Gaël Lejeune (Sorbonne Université) [1] ;
- **Archéologie des systèmes de REN :**
 - Les Insinuations du Châtelet de Paris avec Simon Dagenais (Université de Trèves) → accepté Conf. DH 2026 ;
 - MEGV avec Marion Philipe *et al.* (Université de Genève) ;
- projet mené dans le cadre de la bourse Postdoctorale (24 mois) avec Damien Tricoire (Université de Trèves) ;

Frugalité : OCR sur des images de qualité variable – [1]

Corpus ELTeC¹ = Romans du XIXe siècle

Langues	nb. ouvrages	nb Mots	DPI moyen	Résumé des remarques
- français, - allemand, - espagnol	24	2 945 968	30 → 70	- Corpus allemand : police Fraktur ; - Qualité hétérogène des images

Table 1 – Description des corpus de travail

➤ Évaluations de moteurs OCR pour les 3 langues :

- PADDLEOCR : fr, sp, german
- TESSERACT : fra, spa, deu
- KRAKEN : Catmus, german print.mlmodel

1. European Literary Text Collection :

<https://www.distant-reading.net/eltec/>

- Images **basse qualité** peuvent produire des **OCR correctes**
- Seuil minimal de dégradation pour le corpus avec le DPI moyen à :
 - 70 → 50%
 - 30 → 60%
- PADDLEOCR = moteur le plus robuste
- JPEG = meilleur rapport temps/espace de stockage

Corpus	Documents	Tokens	Caractères
Les Insinuations du Châtelet de Paris : 1539 et 1791	34	4 120 712	26 217 581
Masculinités esclavagistes	637	108 193	630 080

Table 2 – Descriptions des deux corpus utilisés pour l'évaluation diachronique de modèles de REN

→ Systèmes de REN évalués :

- SPACY : 2.3 et 3.8 (mod. fr. large, medium et small)
- STANZA : 1.2.1 (mod. WikiNER) et 1.11.0 (mod. WikiNER-gold)

- Réalisation **Gold standard REN** « Les Insinuations » : 36 000 tokens
- Interroger la **primauté** accordée à la dernière **version disponible**
- Les catégories MISC et ORG sont plus susceptibles d'erreurs

Les mobilités féminines entre les Antilles Française – Martinique, Guadeloupe et Guyane – et la métropole aux 17ème et 18ème siècle.

👉 Livrables 2026 :

- Workpackage 1 – Inventorier des travaux d'historiens existants
→ établir des collaborations
- Workpackage 2 – Numérisation (*cf.* 4)
- Workpackage 3 – Création base de données à partir des numérisations
- Workpackage 4 – Enquête auprès d'historien-ne-s pour comprendre leurs usages des outils numériques :
 - recherches dans les archives,
 - requêtes dans les bases de données.

- État de l'art du domaine
- Valorisation de corpus produits par des historien-ne-s
- Mieux comprendre les usages des historien-ne-s pour élaborer un système adapté à l'exploration des données.

Intégration dans l'équipe

- Images **basse qualité** → Évaluer des tâches de TAL en aval
- Archéologie des outils de REN → Trouver les meilleures **combinaisons** pour les cas d'usage
- FIamma : un moteur de **requêtes croisées** entre bases de données

Problématique

Comment permettre l'interrogation et l'analyse croisées de bases de données hétérogènes en histoire coloniale, sans les centraliser ?

Objectif

- Croiser des sources de données indépendantes ;
- Exploration unifiée des corpus pour les chercheurs en sciences humaines.

Hypothèse de recherche

Concevoir une **couche d'interrogation sémantique**

Axe 1 – Aligement des métadonnées

- Inventaire des plateformes existantes.
- Exploitation des manifestes IIIF.
- Harmonisation des métadonnées archivistiques.

Axe 2 – Extraction de connaissances

- Reconnaissance d'entités nommées.
- Entity Linking de personnes, lieux, institutions et événements.
- Désambiguïsation d'entités historiques.

Axe 3 – Graphe de connaissances historique

- Construction de graphes temporels.
- Analyse de réseaux d'acteurs et d'institutions.
- Cartographie des données.

Références

- [1] Toufik BOUBEHZIZ, Caroline KOUDORO-PARFAIT et Gaël LEJEUNE. **“Assessing the Impact of Image Resolution on OCR Transcription Accuracy.”**. In : *International Workshop on Digital Language Archives : LangArc-2025*. Sous la dir. d'Oksana ZAVALINA. Northern Illinois University and IEEE Computer Society and Association for Computing Machinery. ONLINE, United States : University of North Texas, jan. 2026. DOI : 10.12794/langarc2543322. URL : <https://hal.science/hal-05620753>.

- [2] C. KOUDORO-PARFAIT, L. PETKOVIC et G. ROE. **“Analyse multilingue de l’impact de la correction automatique de la ROC sur la reconnaissance d’entités nommées spatiales dans des corpus littéraires”**. In : *Revue TAL* 64.2 (2023). Sous la dir. de C. CORRO, G. LEJEUNE et V. NICULAE. Multilingual Analysis of the Impact of OCR Correction on Spatial Named Entity Recognition in Literary Corpora, p. 43-67. URL : https://www.atala.org/index.php/content/tal_64_2_2.

- [3] Caroline KOUDORO-PARFAIT et al. **“Epimethee – A Workflow from OCR to Spatial Mapping”**. In : *Document Analysis and Recognition – ICDAR 2025*. Sous la dir. de Xu-Cheng YIN, Dimosthenis KARATZAS et Daniel LOPRESTI. Cham : Springer Nature Switzerland, 2026, p. 3-21. ISBN : 978-3-032-04624-6.

- [4] Françoise LORÉ et Jean-Marie LORÉ. ***Les Premières glanes antillaises dans le notariat nantais de 1673 à 1747***. 15 p. : ill. ; 30 cm. 1988.

- [5] Ljudmila PETKOVIC et al. **“Quelle solution pour améliorer les performances de la reconnaissance d’entités nommées sur des données bruitées, corriger l’entrée ou filtrer la sortie ?”** In : *Corpus* 26 (2025). Mis en ligne le 14 janvier 2025. DOI : 10.4000/1364s. URL : <http://journals.openedition.org/corpus/9059> (visité le 03/06/2026).

Annexes

Détail Workpackage 2 – Numérisation :

➤ AD Loire Atlantique :

- les *Glanes Antillaises dans le notariat Nantais* de 1659 à 1830, dépouillement [4] entre 1988 et 2010

➔ dépôt numérisation :

https://github.com/carolineKParfait/AD_Loire-Atlantique_18122025

➤ AD Seine Maritime :

- *Les engagés pour les antilles 1634 1715*, G. Debien
 - *Les engagés pour les antilles la Rochelle*, G. Debien
 - *Les femmes des premiers colons aux antilles 1635-1680*, G. Debien
 - *Les engagés de Nantes 1636-1660*, J. TANGUY
- ➔ dépôt numérisation :

https://github.com/carolineKParfait/AD_Seine-Maritime_17032026

* Numérisation : CZUR Aura pro