

Audition EPITA – Exposé Enseignement : IAML

Caroline Koudoro-Parfait

parfait@uni-trier.de

<https://hal.science/tel-05042915>

Universität Trier Fachbereich III - Neuere Geschichte

Fiche de cours de 30h

Notion du Tronc Commun – Évolution des méthodes de reconnaissance de texte : des approches classiques aux Transformers

Activités d'enseignement

Projet d'enseignement : IA robuste sur données réelles

Fiche de cours de 30h

IAML – Sortir de l'idéal : évaluation des systèmes d'IA dans des contextes réalistes

→ Objectifs

- comprendre les effets du bruit sur les performances;
- apprendre à évaluer correctement un système;
- distinguer performance théorique et robustesse réelle;
- expérimenter différentes stratégies d'amélioration et de contournement;
- développer une réflexion critique sur les usages et limites des modèles contemporains.

https://carolinekoudoroparfait.github.io/CKP_EPITA_Fiche_programme_30h.pdf

Notion du Tronc Commun – Évolution des méthodes de reconnaissance de texte : des approches classiques aux Transformers

Compétence : savoir **analyser et comparer** des **approches d'OCR** pour choisir un modèle adapté.

Objectifs opérationnels :

- **Identifier les difficultés** des systèmes **OCR** dans des documents réels ;
- **Interpréter** des résultats d'OCR
- **Comparer** différentes architectures (locales, séquentielles, transformers)
- **Justifier** le choix d'un modèle selon un **contexte**

Identifier les difficultés rencontrées par les modèles d'OCR

- Quels **éléments perturbent** la lecture automatique ?
- Toutes les **zones** sont-elles également bien **reconnues** ?
- Quelles **erreurs** pouvez-vous **anticiper** ?


Identifier les difficultés rencontrées par les modèles d'OCR




(a) ?



(b) ?



(c) ?



(d) ?

Identifier les difficultés rencontrées par les modèles d'OCR



(a) Illustration + légende



(b) Texte en colonnes



(c) Texte en filigrane



(d) Décoration, Capitalisation

Figure 3 – a) G. de Maupassant, *Une vie*, 1883. b) Inconnu, *Adélaïde de Mariendal*, drame en cinq actes, 1783. c) Z. Carraud, *La petite Jeanne*, 1884. (d) H. de Balzac, *Albert Savarus*, 1853.

Consigne : Comparer les sorties OCR pour le document suivant.

- Repérer les différences entre les transcriptions
- Relier erreurs et caractéristiques visuelles
- Classer les types d'erreurs observées

La qualité et la structure du document influencent-elles fortement la reconnaissance ?

Document analysé

1732

3
-ARNAULT Jean
Raffineur à la MARTINIQUE.
Sa succession.
(Notariat PARIS 27/11/1731)

- MAITRE BUISSON-

28/6/1723

-MEYER Michel MAITRE. Notaire à la GUADELOUPE.
Dépose son autorisation de passer en FRANCE, signée
du Comte de MOYENCOURT.

12/8/1724

-ROBIT Louis
-ORIEUZE Marie, de VANNES.
Engagement du couple pour aller à St DOMINGUE.

24/11/1724

-FAURE Elie
MARTINIQUE St Pierre.
sa procuration passée à BORDEAUX

17/7/1725

-LECONTE François dit VALOIS de l'Anjou
-CHESNEAU Magdeleine
Engagement du couple et de leur enfant pour la
MARTINIQUE.

27/9/1726

-JOUANIN Louis 38 ans
-JOUANIN Marc 12 ans
de St Fiacre diocèse de NANTES
Engagement du père et du fils pour ST DOMINGUE.

11/4/1730

-SAGUEMILLE Pierre
de St DOMINGUE Lieutenant de Milice.
Testament.

20/10/1730

-GALLOUIN Guillaume
NANTES
Déclaration sur le départ de sa fille, de son gendre
Joseph POITOU et de leur enfant Vincent Louis pour
St DOMINGUE.

10/1730

-JUCHEREAU Augustin sieur du CHESNAY de ST DOMINGUE,
décédé.
-GIGOT Anne son épouse remariée.
-GOBELIN-DAFFERNANT
dépôt de procuration.

27/12/1731

-LE GENTIL Guy
de ST MALO Commissaire de Marine, habitant de ST DOMINGUE
Testament - élément de généalogie.
-CHARING, Vve. François d' ALESSO d'ERAGNY.

Tess. fr 0.3.6	Lamma.cpp
CHEREAUUGa=stin) sic UC URSS DOMINGUE, —JUCHER ugustin décédé. a _GIGOT Anne son épouse remariée- _GOBELIN-DAFFERNANT dépôt de procerat	-JUCHEREAU Augustin sieur du CHESNAY de ST DOMINGUE, décédé. -GIGOT Anne son épouse remariée. -GOBELIN-DAFFERNANT dépôt de procuration.

Table 1 – Transcriptions OCR d'un tableau.

Impact de la qualité de l'image

La date a disparu !


● = décalage,

● = contaminations orthographiques.

Tess. fr 0.3.6	Lamma.cpp
CHEREAU_AUga=stin) sic UC URSS DOMINGUE, —JUCHER _ugustin décédé. a _GIGOT Anne son épouse remariée- _GOBELIN-DAFFERNANT dépôt de procerat	-JUCHEREAU Augustin sieur du CHESNAY de ST DOMINGUE, décédé. -GIGOT Anne son épouse remariée. -GOBELIN-DAFFERNANT dépôt de procuration.

Table 2 – Transcriptions OCR d'un tableau.

Problème : comment reconnaître un caractère ?



Source : <https://patducjacquet.wordpress.com/2017/07/04/cnn-convolution-neural-network-une-introduction/>

Le système lit chaque caractère individuellement

→ modèle de classification (CNN).

→ Forte **dépendance** à la **qualité** de la **segmentation**.

Problèmes :

⇒ un « à » peut être transcrit en « 4 » ou un « ! » en « l » ...

Problème : lever les ambiguïtés de lecture


Exemple : Différencier BANQ_E de BANANE

Questions :

- Faut-il regarder uniquement les caractères ?
- Ou exploiter les mots autour ?

Nécessité du contexte

Prise en compte du contexte : segment par segment




Source : https://www.researchgate.net/figure/The-architecture-of-a-convolutional-recurrent-neural-network-is-composed-of-three_

fig3_348941378

LSTM (*Long Short-Term Memory*) : Mémoire contrôlée du contexte dans une suite de données

→ Prise en compte du contexte via état caché.

Prise en compte du contexte global



Source: <https://neurohive.io/en/news/transformer-model-used-to-recognize-text-in-images/>

Architecture Transformers : Contexte globale et attention

→ Forte parallélisation du calcul.

Situation problème :

Vous êtes chargés de choisir une méthode OCR pour un projet de numérisation de documents anciens.

Travail attendu :

- Comparer plusieurs approches (locale / séquentielle / transformer)
- Justifier votre choix
- Identifier les limites restantes

Activités d'enseignement

➤ **603,5** Heures équivalent TD (HeTD) dont **70 %** en programmation pour le TAL.

- **2026**

- **Programmation pour le TAL.** L3 Humanités numériques, Universität Trier, Allemagne. 42 HeTD
- **Épistémologie des systèmes d'IA pour le TAL.** DSAA Numérique – Grade Master, ENSAAMA, Olivier de Serres 10 HeTD

- **2023–2025**

- 2025 : **Responsable** du CM et TD de **Programmation pour le TAL.** L3 Sciences du langage 105 HeTD
380 HeTD
- ATER – informatique pour les sciences humaines. UFR sociologie et informatique, Sorbonne Université

- **2021–2023**

- **Programmation pour le TAL.** L3 Langues étrangères et TAL. Institut National des Langues et Civilisations Orientales (INALCO) 171,5 HeTD

Encadrement stages et mémoires

📎 1 Stage de M2, 1 stage de L3, 4 mémoires de M1.

date	sujet	Statut	étudiant-e-s	Université
2025	<i>Reconnaissance d'Entités Nommées sur un corpus de poèmes du XIX^e siècle</i>	Mémoire de M1, SDL	LOPES M., ZHENG, R.	SU
2025	<i>Entraînement et évaluation d'un modèle de Reconnaissance d'Entités Nommées sur données bruitées</i>	Mémoire de M1, SDL	FIEF C., CANONGE Y.	SU
2024	<i>Évaluation des problèmes d'étiquetage de la REN.</i>	Stage de L3, SDL	FIEF, C.	SU
2023	<i>Évaluation et développement de méthodes pour la désambiguïsation sémantique d'entités nommées spatiales</i>	Stage de M2, IDCP	DORLÉANS, C.	CESR
2022	<i>Résolution de problèmes d'Entity Linking sur des sorties OCR bruitées</i>	Mémoire de M1, SDL	BUTH, P.-R.	SU
2021	<i>Les lieux de Paris dans la chanson française</i>	Mémoire de M1, SDL	LAZREG, M.	SU

- Publics pluridisciplinaires : langues, sciences du langage, SHS et design numérique.
- Accompagnement vers les masters en TAL
- Transmission de compétences numériques dans des contextes variés.

- Enseignement des **fondamentaux** de la **programmation** et des bonnes pratiques (*Python*, versionnage, métriques).
- Mise en œuvre d'outils de TAL contemporains (*spaCy*, *scikit-learn*, *pandas*, *matplotlib*).
- **Apprentissage par projet** : traduction automatique, annotation de corpus, REN, clustering.
- Articulation entre théorie, expérimentation et **analyse critique** des outils.

- Introduction aux **humanités numériques** et à leurs **enjeux scientifiques**.
- **Épistémologie** des systèmes d'IA
- Mise en perspective des approches symboliques et connexionnistes.
- **Liaison** entre concepts **théoriques** et **applications concrètes** en TAL.

Projet d'enseignement : IA robuste sur données réelles

- ☞ Former des ingénieur·e·s capables de **concevoir des outils** :
 - **adaptés** aux besoins des **utilisateurs**;
 - intégrant les enjeux de **robustesse**;
 - intégrant les enjeux de **frugalité** et d'**accessibilité**.
- ☞ Développer le **recul critique** sur les pratiques, pour en **comprendre** les enjeux scientifiques et sociétaux.
- ☞ **Mobiliser les compétences** acquises de manière **éclairée** dans des **contextes professionnels**.

Problématique

Comment concevoir et évaluer un système d'IA performant à partir de données réelles, bruitées et hétérogènes ?

Fil rouge

Du bruit aux décisions : la robustesse des systèmes en conditions réelles

Objectifs du projet de recherche

Proposer aux étudiant·e·s :

- d'**analyser** et caractériser le **bruit**;
- l'analyse de données à **grande échelle**;
- d'**évaluer** des systèmes **existants**;
- **Identifier** les problèmes d'entraînement (sur/sous-apprentissage);
- évaluation **critique** des performances;
- proposition d'améliorations ou de **stratégies hybrides**.