

Audition EPITA Fiche programme 30h

Intelligence artificielle et Machine Learning - IAML

Caroline Koudoro-Parfait

May 2026

Sortir de l'idéal : évaluation des systèmes d'IA dans des contextes réalistes

1 Informations générales

- **UE** : Intelligence Artificielle et Machine Learning
- **Volume horaire** : 30 heures
- **Organisation** : 10 séances (CM/TD)
- **Effectif CM** : de 400 à 500 étudiant·e·s
- **Effectif TD** : de 30 à 40 étudiant·e·s

Pré-requis

- Bases de programmation

2 Présentation du cours

L'intelligence artificielle est souvent évaluée dans des environnements contrôlés à partir de jeux de données propres, annotés et homogènes. Cette approche masque cependant une partie importante des difficultés rencontrées lors d'applications réelles.

Ce cours propose une approche expérimentale et critique du machine learning et du traitement automatique des langues (TAL/NLP) à travers l'étude de données imparfaites, bruitées et hétérogènes : archives numérisées, OCR dégradés, réseaux sociaux, avis utilisateurs et données web scrapées.

L'objectif pédagogique est de confronter les étudiant·e·s aux limites concrètes des systèmes d'IA afin de :

- comprendre les effets du bruit sur les performances ;
- apprendre à évaluer correctement un système ;
- distinguer performance théorique et robustesse réelle ;
- expérimenter différentes stratégies d'amélioration et de contournement ;
- développer une réflexion critique sur les usages et limites des modèles contemporains.

Le cours alterne apports théoriques, expérimentations pratiques et analyses critiques.

3 Contenu et plan du cours

3.1 Séance 1 — Introduction : l'IA hors laboratoire

Notions

- IA en laboratoire vs IA en contexte réel
- Jeux de données académiques et biais expérimentaux
- Sources de données réelles : données bruitées et hétérogènes
- Bruit lexical, sémantique et structurel
- Introduction : Impact du bruit sur les modèles ML

Expérimentation

- Étude de cas : transcription automatique
- Comparaison OCR classique vs lecture visuelle par LLM
- Analyse des erreurs de transcription
- Discussion sur les limites des systèmes

Verrou

Sortir de l'illusion des données parfaites. Les étudiant-e-s sont souvent exposés à des jeux de données propres, homogènes et soigneusement annotés.

- identifier les différentes formes de bruit ;
- comprendre les spécificités des données réelles ;
- analyser l'impact du bruit sur les performances des systèmes ;
- développer une démarche exploratoire avant toute modélisation.

3.2 Séance 2 — Évaluation des modèles I : métriques classiques

Notions

- **Accuracy**
- Matrice de confusion
- Précision / rappel
- F1-score
- Limites des métriques globales

Expérimentation

- Étude de cas : Évaluation d'un modèle de classification
- Analyse des erreurs
- Étude des cas limites
- Comparaison de métriques

Verrou

Comprendre qu'un score élevé ne garantit pas un système utile. Les performances sont souvent résumées à une unique métrique globale.

- interpréter correctement les métriques d'évaluation ;
- distinguer précision locale et performance globale ;
- analyser les erreurs produites par les modèles ;
- comprendre les limites des benchmarks académiques.

3.3 Séance 3 — Évaluation des modèles II : distances et similarités

Notions

- Distances textuelles
- Levenshtein, CER, WER

- BLEU et ROUGE
- Similarité cosinus
- Embeddings et représentations vectorielles

Expérimentation

- Étude de cas : Comparaison de métriques sur corpus NLP
- Similarité syntaxique vs similarité sémantique

Verrou

Évaluer un système en l'absence de vérité terrain parfaite. Les protocoles académiques supposent souvent l'existence d'annotations fiables.

- travailler avec des annotations incomplètes ou imparfaites ;
- comprendre la notion de *silver standard* ;
- mettre en place des stratégies d'évaluation indirecte ;
- estimer l'incertitude associée aux mesures obtenues.

3.4 Séance 4 — Évaluation des modèles III : mesurer l'impact du bruit

Notions

- Évaluation sans vérité terrain
- Silver Standard
- Validation indirecte
- Limites des protocoles d'évaluation

Expérimentation

- Étude de cas : Classification supervisée sur données bruitées
- Régression logistique
- Mesure des performances : Comparaison *silver standard* vs données bruitées

Verrou

Trouver le bon niveau de nettoyage des données. Le nettoyage est souvent perçu comme une opération systématiquement bénéfique.

- distinguer correction et sur-correction ;
- mesurer la perte potentielle d'information ;
- comparer différentes stratégies de prétraitement ;
- évaluer l'impact du nettoyage sur les tâches en aval.

3.5 Séance 5 — Prétraitement et nettoyage

Notions

- Nettoyage, **normalisation**, **standardisation**
- Sur-correction
- Perte d'information ?

Expérimentation

- Étude de cas : Correction automatique de textes OCR
- Correction symbolique vs neuronale
- Bonus : Analyse de l'impact sur les tâches aval

Verrou

Comprendre le rôle central des données dans l'apprentissage. Les performances sont souvent attribuées uniquement au choix de l'algorithme.

- analyser la qualité des données d'entraînement ;
- comprendre le compromis biais-variance ;

- travailler dans des contextes de faible quantité de données ;
- relier erreurs observées et caractéristiques du jeu de données.

3.6 Séance 6 — Entraînement et robustesse des modèles

Notions

- Pipeline ML
- Train / validation / test
- Surapprentissage
- Généralisation
- **Biais / variance**
- Robustesse vs performance

Expérimentation

- Étude de cas : Entraînement d'un modèle de classification
- quelles difficultés ? :
 - frugalité en données (few-shot / low-data)
 - frugalité computationnelle
 - qualité et bruit des données d'entraînement
- **Régression logistique** ou **Random Forest**
- Tests de robustesse :
 - ajout de bruit ;
 - valeurs aberrantes ;
 - **changement de distribution.**

Verrou

Faire face aux changements de distribution. Un modèle performant sur un jeu de test est souvent considéré comme robuste.

- comprendre les mécanismes de généralisation ;
- identifier les effets du changement de distribution ;
- mesurer la robustesse face au bruit et aux valeurs aberrantes ;
- distinguer performance expérimentale et performance en situation réelle.

3.7 Séance 7 — Apprentissage non supervisé

Notions

- Introduction au clustering
- K-means
- **ACP (PCA)**
- **Réduction de dimension**
- **Espaces latents**
- Similarité sémantique

Expérimentation, Projet de groupe

- Étude de cas : Clustering de phrases
- ACP et visualisation 2D
- Interprétation des clusters et explicabilité des modèles : Un cluster statistique correspond-il à une catégorie sémantique compréhensible ?
- Évaluer les clusters : Homogeneity score, Completeness score et V-measure

Détails : Projet de groupe (4 étudiant·e·s)

À partir des expérimentations réalisées lors de cette séance, les étudiant·e·s devront conduire un projet en équipe. Le projet sera poursuivi en autonomie au cours des semaines suivantes, durant le temps de travail personnel.

Modalité d'évaluation (modalités de la présentation orale cf. séance 10)

Chaque groupe devra remettre :

- une implémentation commune
- un support pour la présentation orale
- un rapport individuel pour chaque membre.

Le code devra être versionné et déposé sur une plateforme de gestion de versions (par exemple Git). Chaque étudiant·e doit contribuer activement au développement du projet, avec un historique de commits attestant de sa participation. Le projet devra être remis avant la séance 10 et sera présenté en groupe lors de cette même séance.

Compétences

La conduite de ce projet vise à amener les étudiants à s'informer de manière autonome et à développer un esprit critique vis-à-vis des algorithmes de clustering ainsi que des méthodes d'évaluation associées. Ils sont également amenés à acquérir de bonnes pratiques de gestion de version du code. Enfin, la rédaction du rapport et la préparation de la soutenance constituent une première initiation aux standards de rédaction scientifique et industrielle.

Verrou

Interpréter des représentations statistiques complexes. Les regroupements produits par les algorithmes sont parfois considérés comme naturellement interprétables alors qu'il faudrait les interroger et les évaluer.

- comprendre les espaces vectoriels et les représentations latentes ;
- interpréter les résultats d'un clustering ;
- distinguer proximité statistique et proximité sémantique ;
- questionner l'explicabilité des regroupements observés et les évaluer.
- Apprendre à utiliser un système de versionnage dans un travail collaboratif en équipe.

3.8 Séance 8 — Amélioration des modèles

Notions

- Amélioration par les données
- **Feature engineering**
- Introduction au **fine-tuning**
- **Descente de gradient**
- **Fonction de perte**

Expérimentation

- Étude de cas : Optimisation d'un modèle de classification
- Ajustement progressif des paramètres
- Observation de l'évolution des performances

Verrou

Comprendre les mécanismes d'amélioration d'un modèle. Les processus d'optimisation sont souvent perçus comme des boîtes noires.

- comprendre le rôle de la fonction de perte ;
- relier paramètres, données et performances ;
- analyser les effets des ajustements réalisés ;
- distinguer amélioration réelle et surapprentissage.

3.9 Séance 9 — Stratégies de contournement

Notions

- Approches hybrides
- Combinaison de systèmes IA
- Validation croisée entre modèles
- Pipelines composites et IA génératives : introduction au **RAG**

Expérimentation

- Étude de cas : Résolution d’une tâche NLP multi-outils
- Comparaison de systèmes
- Agrégation de sorties
- Analyse des divergences

Verrou

Accepter qu’il n’existe pas de solution unique. Les étudiant·e·s recherchent souvent un modèle universel capable de résoudre un problème donné.

- comparer plusieurs approches ;
- construire des systèmes hybrides ;
- exploiter la complémentarité de plusieurs modèles ;
- concevoir des pipelines adaptés à un contexte d’usage réel.

3.10 Séance 10 — Restitution des projets

Dispositif

- Présentation orale du projet mené par un groupe (*cf.* la séance 7) = 15 min :
 - 10 min de présentation
 - 5 minute de question
- Un autre groupe est désigné pour former le jury avec l’enseignant et doit préparer des questions (écoute active)
- Feedback collectif

Verrou

Développer une posture critique vis-à-vis des systèmes d’IA. Les résultats produits par les modèles sont parfois perçus comme objectifs ou intrinsèquement fiables.

- Management d’un projet en groupe
- Gestion du versionnage de programme
- identifier les limites méthodologiques des expérimentations ;
- comprendre les biais liés aux données et aux protocoles ;
- justifier scientifiquement les conclusions produites ;
- développer une réflexion critique sur les usages et les limites de l’IA contemporaine.

4 Format des activités

Cours magistraux (1h) Introduction : l’IA hors laboratoire
Travaux dirigés (2h) Étude de cas : transcription automatique
Cours magistraux (1h) Évaluation des modèles I : métriques classiques
Travaux dirigés (2h) Étude de cas : classification et analyse d’erreurs
Cours magistraux (1h) Évaluation des modèles II : distances et similarités
Travaux dirigés (2h) Étude de cas : comparaison de métriques NLP
Cours magistraux (1h) Évaluation des modèles III : impact du bruit

Travaux dirigés (2h) Classification sur données bruitées
 Cours magistraux (1h) Prétraitement et nettoyage
 Travaux dirigés (2h) Correction de textes OCR
 Cours magistraux (1h) Entraînement et robustesse des modèles
 Travaux dirigés (2h) Entraînement et tests de robustesse
 Cours magistraux (1h) Apprentissage non supervisé
 Projet (2h) Clustering et visualisation de données
 Cours magistraux (1h) Amélioration des modèles
 Travaux dirigés (2h) Optimisation d'un modèle de classification
 Cours magistraux (1h) Stratégies de contournement
 Travaux dirigés (2h) Projet NLP multi-outils
 Projet (3h) Restitution des projets

5 Acquis des apprentissages attendus

À l'issue du cours, les étudiant·e·s seront capables de :

- Évaluer et comparer des modèles d'IA à l'aide de métriques adaptées, tout en identifiant leurs limites.
- Comprendre les principales étapes d'un pipeline de machine learning ;
- Construire une démarche expérimentale reproductible et critique permettant d'interpréter les résultats et de comparer différents systèmes d'IA.

6 Évaluation des acquis d'apprentissage attendus

Projet (40 %) Exercices (TD) (40 %) Examen final (20 %)

A l'issue de chaque TD les étudiant·e·s doivent envoyer leur réalisation.

L'examen final se compose d'un QCM concernant les points théoriques du CM.

7 Bibliographie indicative

Buscaldi, D., Felhi, G., Ghoul, D., Le Roux, J., Lejeune, G., & Zhang, X. (2020). Calcul de similarité entre phrases : quelles mesures et quels descripteurs ? (Sentence Similarity : a study on similarity metrics with words and character strings). In Actes de la 6e conférence conjointe Journées d'Études sur la Parole (JEP, 33e édition), Traitement Automatique des Langues Naturelles (TALN, 27e édition), Rencontre des Étudiants Chercheurs en Informatique pour le Traitement Automatique des Langues (RÉCITAL, 22e édition), Atelier Défi Fouille de Textes (pp. 14–25).

Martin, L., Muller, B., Ortiz Suárez, P. J., Dupont, Y., Romary, L., de la Clergerie, É., Seddah, D., & Sagot, B. (2020). CamemBERT : a Tasty French Language Model. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (pp. 7203–7219). Association for Computational Linguistics. <https://www.aclweb.org/anthology/2020.acl-main.645>

Rebholz-Schuhmann D, Jimeno Yepes A, Li C, Kafkas S, Lewin I, et al. (2011). Assessment of NER solutions against the first and second CALBC Silver Standard Corpus. J Biomed Semantics. 2011 Oct 6;2 Suppl 5(Suppl 5) :S11. doi : 10.1186/2041-1480-2-S5-S11. PMID : 22166494 ; PMCID : PMC3239301.

van Strien, D., Beelen, K., Ardanuy, M., Hosseini, K., McGillivray, B., & Colavizza, G. (2020). Assessing the Impact of OCR Quality on Downstream NLP Tasks. In Proceedings of the 12th International Conference on Agents and Artificial Intelligence – Volume 1 : ARTIDIGH (pp. 484–496). <https://doi.org/10.5220/0009169004840496>

Wisniewski, G., Zhu, L. , Younès, J.-B., Ballier, N. (2022). La robustesse de la traduction neuronale : les systèmes de traduction automatique neuronale à l' épreuve de la reproductibilité de l'expérience. Journée d'étude "Robustesse des systemes de TAL", Nov 2022, Paris, France. <hal-03912352>